

### Оптимальное кодирование.

Построить коды Фано и Хаффмана, найти цены кодирования, сравнить с энтропией и длиной равномерного кода:

1.  $A = (a_1, \dots, a_{12})$ ,  $B = \{0, 1\}$ ,  $p = (0, 18; 0, 139; 0, 128; 0, 113; 0, 103; 0, 098; 0, 097; 0, 059; 0, 044; 0, 017; 0, 013; 0, 009)$ .
2.  $A = (a_1, \dots, a_{12})$ ,  $B = \{0, 1\}$   $p = (0, 094; 0, 066; 0, 052; 0, 138; 0, 148; 0, 033; 0, 009; 0, 002; 0, 101; 0, 117; 0, 103; 0, 137)$ .
3.  $A = \{0, 1\}$ ,  $p = \{2/3, 1/3\}$ . Построить код Хаффмана для множества  $A^3$ , состоящего из всех слов длины 3. Найти среднее количество бит на символ, сравнить со средней ценой оптимального побуквенного кодирования и энтропией.
- 4.\* Рассмотреть кодирование русского и английского алфавитов.
- 5.\* Случайная величина  $X$  задана распределением  $P(X = 2^n) = 1/2^n$ ,  $n = 1, 2, \dots$  Найти энтропию  $X$ . Придумать оптимальное кодирование для  $X$ , вычислить его среднюю длину.

**Алгоритм построения кода Фано** (или Шеннона–Фано).

Для алфавита  $A = \{a_1, \dots, a_m\}$  известны вероятности появления букв в сообщении  $p_1 \geq \dots \geq p_m > 0$ . Алфавит  $A$  разбивается на две группы  $A_1 = \{a_1, \dots, a_k\}$  и  $A_2 = \{a_{k+1}, \dots, a_m\}$  так, чтобы суммарные вероятности в каждой группе были как можно ближе друг другу, т.е. определяется номер  $k$  такой, что

$$|(p_1 + p_2 + \dots + p_k) - (p_{k+1} + p_{k+2} + \dots + p_m)| \leq |(p_1 + p_2 + \dots + p_l) - (p_{l+1} + p_{l+2} + \dots + p_m)| \quad \forall l = 1, \dots, m.$$

Буквам первой группы приписывается код 0, второй — 1. После этого каждая из полученных групп  $A_1, A_2$  снова разбивается на две с наиболее близкими суммарными вероятностями. К коду букв первой из полученных подгрупп приписывается 0, второй 1. И т.д. Каждая группа разбивается до тех пор, пока в не останется одна буква. Коды всех букв построены. По построению схема является префиксной, а значит и разделимой.

**Пример.**  $p = (0.4; 0.2; 0.2; 0.1; 0.05; 0.05)$ . Получим таблицу (жирным шрифтом выделены элементарные коды букв).

0,4	0	<b>00</b>		
0,2	0	<b>01</b>		
0,2	1	<b>10</b>		
0,1	1	11	<b>110</b>	
0,05	1	11	111	<b>1110</b>
0,05	1	11	111	<b>1111</b>

Таблица частот букв для английского текста

$A - 0,082$	$B - 0,014$	$C - 0,028$	$D - 0,038$	$E - 0,131$	$F - 0,029$	$G - 0,020$	$H - 0,053$	$I - 0,063$
$J - 0,001$	$K - 0,004$	$L - 0,034$	$M - 0,025$	$N - 0,071$	$O - 0,080$	$P - 0,020$	$Q - 0,001$	$R - 0,068$
$S - 0,061$	$T - 0,105$	$U - 0,025$	$V - 0,009$	$W - 0,015$	$X - 0,002$	$Y - 0,020$	$Z - 0,001$	

Таблица частот букв для русского текста

$a - 0,0802$	$б - 0,0159$	$в - 0,0435$	$г - 0,0178$	$д - 0,0320$	$е - 0,0848$	$ё - 0,0037$	$ж - 0,0091$	$з - 0,0167$
$и - 0,0723$	$й - 0,0100$	$к - 0,0353$	$л - 0,0470$	$м - 0,0371$	$н - 0,0673$	$о - 0,1110$	$п - 0,0275$	$р - 0,0458$
$с - 0,0536$	$т - 0,0597$	$у - 0,0234$	$ф - 0,0027$	$х - 0,0074$	$ц - 0,0048$	$ч - 0,0149$	$ш - 0,0062$	$щ - 0,0032$
$ъ - 0,0003$	$ы - 0,0192$	$ь - 0,0179$	$э - 0,0038$	$ю - 0,0062$	$я - 0,0197$			

### Оптимальное кодирование.

Построить коды Фано и Хаффмана, найти цены кодирования, сравнить с энтропией и длиной равномерного кода:

1.  $A = (a_1, \dots, a_{12})$ ,  $B = \{0, 1\}$ ,  $p = (0, 18; 0, 139; 0, 128; 0, 113; 0, 103; 0, 098; 0, 097; 0, 059; 0, 044; 0, 017; 0, 013; 0, 009)$ .
2.  $A = (a_1, \dots, a_{12})$ ,  $B = \{0, 1\}$   $p = (0, 094; 0, 066; 0, 052; 0, 138; 0, 148; 0, 033; 0, 009; 0, 002; 0, 101; 0, 117; 0, 103; 0, 137)$ .
3.  $A = \{0, 1\}$ ,  $p = \{2/3, 1/3\}$ . Построить код Хаффмана для множества  $A^3$ , состоящего из всех слов длины 3. Найти среднее количество бит на символ, сравнить со средней ценой оптимального побуквенного кодирования и энтропией.
- 4.\* Рассмотреть кодирование русского и английского алфавитов.
- 5.\* Случайная величина  $X$  задана распределением  $P(X = 2^n) = 1/2^n$ ,  $n = 1, 2, \dots$  Найти энтропию  $X$ . Придумать оптимальное кодирование для  $X$ , вычислить его среднюю длину.

**Код Фано** (или код Шеннона–Фано).

Для алфавита  $A = \{a_1, \dots, a_m\}$  известны вероятности появления букв в сообщении  $p_1 \geq \dots \geq p_m > 0$ . Алфавит  $A$  разбивается на две группы  $A_1 = \{a_1, \dots, a_k\}$  и  $A_2 = \{a_{k+1}, \dots, a_m\}$  так, чтобы суммарные вероятности в каждой группе были как можно ближе друг другу, т.е. определяется номер  $k$  такой, что

$$|(p_1 + p_2 + \dots + p_k) - (p_{k+1} + p_{k+2} + \dots + p_m)| \leq |(p_1 + p_2 + \dots + p_l) - (p_{l+1} + p_{l+2} + \dots + p_m)| \quad \forall l = 1, \dots, m.$$

Буквам первой группы приписывается код 0, второй — 1. После этого каждая из полученных групп  $A_1, A_2$  снова разбивается на две с наиболее близкими суммарными вероятностями. К коду букв первой из полученных подгрупп приписывается 0, второй 1. И т.д. Каждая группа разбивается до тех пор, пока в не останется одна буква. Коды всех букв построены. По построению схема является префиксной, а значит и разделимой.

**Пример.**  $p = (0.4; 0.2; 0.2; 0.1; 0.05; 0.05)$ . Получим таблицу (жирным шрифтом выделены элементарные коды букв).

0,4	0	<b>00</b>		
0,2	0	<b>01</b>		
0,2	1	<b>10</b>		
0,1	1	11	<b>110</b>	
0,05	1	11	111	<b>1110</b>
0,05	1	11	111	<b>1111</b>

Таблица частот букв для русского текста

$a - 0,0802$	$б - 0,0159$	$в - 0,0435$	$г - 0,0178$	$д - 0,0320$	$е - 0,0848$	$ё - 0,0037$	$ж - 0,0091$	$з - 0,0167$
$и - 0,0723$	$й - 0,0100$	$к - 0,0353$	$л - 0,0470$	$м - 0,0371$	$н - 0,0673$	$о - 0,1110$	$п - 0,0275$	$р - 0,0458$
$с - 0,0536$	$т - 0,0597$	$у - 0,0234$	$ф - 0,0027$	$х - 0,0074$	$ц - 0,0048$	$ч - 0,0149$	$ш - 0,0062$	$щ - 0,0032$
$ъ - 0,0003$	$ы - 0,0192$	$ь - 0,0179$	$э - 0,0038$	$ю - 0,0062$	$я - 0,0197$			